

Análise Comparativa entre Algoritmo Genético e Simulated Annealing Aplicados ao Problema da Mochila 0/1

João Vitor F. da Silva, Marcos Antonio da S. Manuares, Samuel C. Dias

¹Centro de Ciências Exatas e Tecnológicas - Universidade Federal do Acre
Rio Branco - AC - Brasil

{joao.vitor.f.s, marcos.manuares, samuel.dias}@sou.ufac.br

Abstract. *This work compares Genetic Algorithm (GA) and Simulated Annealing (SA) metaheuristics applied to the 0/1 Knapsack Problem using the same strongly correlated instance with 1,000 items. Three parameter configurations were evaluated for each metaheuristic, with ten executions per configuration. The results were organized on a standardized scale of 10,000 tracking positions, recording the best objective-function value found up to each point. Final averages and sample standard deviations were used to assess solution quality and variability. Among the GA configurations, Variation 1 achieved the best final average, with 44,198.8 units and a standard deviation of 383.51. For SA, Variation 2 obtained the best result, with an average of 49,833.3 units and a standard deviation of 45.38. This represents an average advantage of 5,634.5 units, or approximately 12.75%, over the best GA configuration. Under the evaluated conditions, SA Variation 2 achieved the best average performance and lower variability. These results are descriptive and restricted to the analyzed instance and parameter settings.*

Resumo. *Este trabalho compara as metaheurísticas Algoritmo Genético (AG) e Simulated Annealing (SA) aplicadas ao Problema da Mochila 0/1, utilizando a mesma instância fortemente correlacionada com 1.000 itens. Foram avaliadas três configurações de parâmetros para cada metaheurística, com dez execuções por configuração. Os resultados foram organizados em uma escala padronizada de 10.000 posições de acompanhamento, registrando o melhor valor da função objetiva encontrado até cada ponto. As médias finais e os desvios-padrão amostrais foram utilizados para avaliar a qualidade e a variabilidade dos resultados. Entre as configurações do AG, a Variação 1 apresentou a melhor média final, com 44.198,8 unidades e desvio-padrão de 383,51. No SA, a Variação 2 obteve o melhor resultado, com média de 49.833,3 e desvio-padrão de 45,38. Isso representa vantagem média de 5.634,5 unidades, aproximadamente 12,75%, em relação à melhor configuração do AG. Nas condições avaliadas, o SA Variação 2 apresentou o melhor desempenho médio e menor variabilidade. Os resultados são descritivos e restritos à instância e às parametrizações analisadas.*

1. Introdução

Problemas de otimização combinatória estão presentes em diversas áreas, como ciência da computação, engenharia, logística, finanças e pesquisa operacional. Esses problemas envolvem a busca pela melhor solução dentre um conjunto de possibilidades, respeitando determinadas restrições. À medida que o tamanho das instâncias aumenta, o espaço de soluções pode crescer rapidamente, tornando computacionalmente custosa a obtenção de soluções ótimas por métodos exatos. Entre os problemas clássicos dessa categoria encontra-se o Problema da Mochila 0/1 (*0/1 Knapsack Problem*), no qual se deseja selecionar um subconjunto de itens, cada um associado a um peso e a um valor, de modo a maximizar o valor total sem ultrapassar a capacidade disponível da mochila [Hillier and Lieberman 2006].

Diante da dificuldade de resolução de instâncias de maior dimensão, métodos aproximados e metaheurísticas constituem alternativas para a obtenção de soluções de boa qualidade sem a necessidade de explorar exaustivamente todo o espaço de busca. Entre essas abordagens estão o Algoritmo Genético (AG) e o *Simulated Annealing* (SA), que empregam estratégias distintas de exploração do espaço de soluções. O Algoritmo Genético trabalha com uma população de soluções que evolui ao longo das gerações por meio de mecanismos como seleção, cruzamento e mutação [Goldberg 1989]. O *Simulated Annealing*, por sua vez, utiliza uma única solução corrente e um mecanismo probabilístico de aceitação que permite, principalmente em temperaturas mais elevadas, a aceitação temporária de movimentos que reduzem a qualidade da solução [Kirkpatrick et al. 1983].

O desempenho dessas metaheurísticas pode variar de acordo com seus parâmetros e com as características da instância considerada. Dessa forma, a avaliação de diferentes configurações permite observar como alterações nos mecanismos de busca influenciam a evolução e a qualidade das soluções encontradas. Neste trabalho, é utilizada uma instância fortemente correlacionada (*strongly correlated*) do Problema da Mochila 0/1, caracterizada por uma relação direta entre o peso e o lucro dos itens. Instâncias dessa natureza constituem um cenário apropriado para a avaliação experimental de estratégias metaheurísticas de otimização [Moradi et al. 2021].

Neste contexto, este trabalho realiza uma análise comparativa entre o Algoritmo Genético e o *Simulated Annealing* aplicados ao Problema da Mochila 0/1. Para cada metaheurística são avaliadas três configurações, totalizando seis configurações experimentais, com dez execuções realizadas para cada configuração. Os resultados são organizados em uma escala padronizada de 10.000 posições de acompanhamento, nas quais é registrado o melhor valor da função objetiva encontrado ao longo da execução. A comparação considera principalmente a evolução média do melhor valor acumulado, os resultados médios finais e a variabilidade observada entre as execuções. Dessa forma, busca-se analisar a influência das diferentes parametrizações sobre o comportamento das metaheurísticas e identificar, dentro das condições estabelecidas para o experimento e para a instância analisada, as configurações que apresentam os melhores resultados.

2. Fundamentação Teórica

2.1. Problema da Mochila 0/1

O Problema da Mochila 0/1 é um problema clássico de otimização combinatória cujo objetivo consiste em selecionar um subconjunto de itens de modo a maximizar o valor total obtido, respeitando uma restrição de capacidade. Cada item está associado a um peso e a um valor, e a decisão consiste em determinar quais itens devem ou não ser incluídos na mochila. Segundo [Hillier and Lieberman 2006], problemas dessa natureza podem ser representados por variáveis binárias, nas quais cada decisão assume apenas os valores 0 ou 1. A denominação “0/1” decorre justamente dessa característica: cada item pode ser selecionado integralmente ou permanecer fora da solução.

Considerando um conjunto de n itens, seja p_i o valor ou lucro associado ao item i , w_i o seu peso e W a capacidade máxima da mochila. Define-se ainda a variável binária x_i , que indica se o item i foi selecionado. A formulação matemática do problema pode ser representada por [Hillier and Lieberman 2006]:

- **Função objetivo:**

$$\max \sum_{i=1}^n p_i x_i$$

- **Restrição de capacidade:**

$$\sum_{i=1}^n w_i x_i \leq W$$

- **Variáveis de decisão:**

$$x_i \in \{0, 1\}, \quad i = 1, 2, \dots, n.$$

Nesse modelo, $x_i = 1$ indica que o item i pertence à solução, enquanto $x_i = 0$ indica sua exclusão. Dessa forma, busca-se obter a combinação de itens que apresente o maior valor total possível sem que a soma de seus pesos ultrapasse a capacidade W .

À medida que o número de itens aumenta, o espaço de soluções possíveis também cresce rapidamente, podendo tornar computacionalmente custosa a obtenção de uma solução ótima por métodos exatos em instâncias de maior dimensão. Nesse contexto, métodos aproximados e metaheurísticas podem ser empregados na busca por soluções de boa qualidade sem a necessidade de avaliar exaustivamente todas as combinações possíveis. Entre essas abordagens encontram-se o Algoritmo Genético e o *Simulated Annealing*, que utilizam estratégias distintas para explorar o espaço de soluções [Hillier and Lieberman 2006].

2.2. Algoritmo Genético

O Algoritmo Genético (AG) é um método de busca e otimização inspirado em princípios da evolução natural, como seleção, reprodução e variação genética [Goldberg 1989, Hillier and Lieberman 2006]. Seu funcionamento baseia-se na manutenção de uma população de soluções candidatas que evolui ao longo de sucessivas gerações. Cada indivíduo da população representa uma possível solução para o problema e é codificado por meio de uma estrutura denominada cromossomo, cujas posições, ou genes, representam as características da solução.

No Problema da Mochila 0/1, uma representação comum utiliza cromossomos binários. Cada gene corresponde a um dos itens disponíveis e assume valor 1 quando o item está presente na solução e 0 quando ele não é selecionado. Assim, um indivíduo pode ser representado por um vetor binário

$$X = (x_1, x_2, \dots, x_n),$$

em que $x_i \in \{0, 1\}$.

Inicialmente, uma população de soluções é gerada e cada indivíduo é avaliado por uma função de aptidão (*fitness*), responsável por quantificar a qualidade da solução representada. No caso do Problema da Mochila, essa avaliação pode considerar o valor total dos itens selecionados e o atendimento à restrição de capacidade [Goldberg 1989, Hillier and Lieberman 2006].

A evolução da população ocorre por meio da aplicação sucessiva de operadores genéticos. Entre os principais operadores encontram-se [Goldberg 1989, Hillier and Lieberman 2006]:

- **Seleção:** determina quais indivíduos terão maior probabilidade de participar do processo de reprodução, normalmente favorecendo soluções com maior aptidão;
- **Cruzamento (*crossover*):** combina informações genéticas de dois ou mais indivíduos selecionados para produzir novos descendentes;
- **Mutação:** modifica aleatoriamente determinados genes dos indivíduos, introduzindo variações que podem contribuir para a exploração de novas regiões do espaço de busca.

Esses operadores estabelecem um equilíbrio entre a exploração de diferentes regiões do espaço de soluções e o aproveitamento de características presentes em soluções de maior qualidade. A escolha dos métodos de seleção e cruzamento, da taxa de mutação, do tamanho da população e de mecanismos como elitismo pode influenciar o comportamento do algoritmo.

O processo evolutivo é repetido até que algum critério de parada seja satisfeito, como um número máximo de gerações, um limite de avaliações da função objetivo ou a ausência de melhorias durante determinado período. Por não depender de propriedades como continuidade ou diferenciabilidade da função objetivo, o Algoritmo Genético pode ser aplicado a diferentes classes de problemas de otimização combinatória [Goldberg 1989, Hillier and Lieberman 2006].

2.3. *Simulated Annealing*

O *Simulated Annealing* (SA) é uma metaheurística inspirada no processo físico de recozimento de sólidos e nos princípios da mecânica estatística [van Laarhoven and Aarts 1987]. No processo físico, um material é inicialmente aquecido e posteriormente submetido a um resfriamento gradual, permitindo que suas partículas se reorganizem até que o sistema alcance estados progressivamente mais estáveis. Na otimização combinatória, essa analogia é utilizada para controlar a exploração do espaço de soluções ao longo da execução do algoritmo.

O método trabalha, em geral, com uma única solução corrente. A partir dela, são produzidas soluções vizinhas por meio de pequenas perturbações. A decisão de substituir a solução corrente pela solução candidata é baseada na diferença entre suas avaliações e em um parâmetro denominado temperatura.

Em sua formulação clássica para problemas de minimização, uma solução candidata que apresenta menor custo é aceita diretamente. Quando a solução candidata apresenta custo superior, ela ainda pode ser aceita com determinada probabilidade, normalmente expressa pelo critério de Metropolis [Metropolis et al. 1953, van Laarhoven and Aarts 1987]. Uma forma comum desse critério é

$$P(\text{aceitar}) = \exp\left(-\frac{\Delta E}{T}\right),$$

em que ΔE representa a variação da função de energia ou custo e T representa a temperatura atual.

A possibilidade de aceitar temporariamente movimentos que pioram a solução corrente diferencia o *Simulated Annealing* de métodos que aceitam exclusivamente movimentos de melhoria. Em temperaturas elevadas, a probabilidade de aceitação desses movimentos é maior, favorecendo uma exploração mais ampla do espaço de busca. À medida que a temperatura diminui, a aceitação de movimentos desfavoráveis torna-se menos frequente e a busca passa a se concentrar progressivamente nas regiões de maior qualidade [Hillier and Lieberman 2006, van Laarhoven and Aarts 1987].

Como o Problema da Mochila tratado neste trabalho possui uma função objetivo de maximização, a lógica do critério pode ser adaptada para considerar a variação do lucro entre a solução candidata e a solução corrente. Dessa forma, soluções que apresentam aumento da função objetivo são aceitas diretamente, enquanto movimentos que reduzem temporariamente o valor da solução podem ser aceitos probabilisticamente, dependendo da temperatura e da magnitude da redução.

A temperatura é atualizada ao longo da execução por meio de um cronograma de resfriamento (*cooling schedule*). Uma forma comum de realizar essa atualização é utilizar uma redução geométrica,

$$T_{k+1} = \alpha T_k,$$

em que T_k representa a temperatura atual e α é o fator de resfriamento. Valores de α mais próximos de 1 produzem uma redução mais lenta da temperatura, enquanto valores menores resultam em um resfriamento mais rápido.

Além do cronograma de temperatura, o comportamento do algoritmo também depende da maneira como as soluções vizinhas são produzidas. Em problemas representados por vetores binários, como o Problema da Mochila 0/1, uma estratégia consiste em alterar uma ou mais posições da solução corrente. O número de posições modificadas influencia o tamanho dos movimentos realizados no espaço de busca e, consequentemente, o equilíbrio entre exploração e refinamento das soluções.

Dessa forma, parâmetros como temperatura inicial, temperatura mínima, fa-

tor de resfriamento, número de iterações em cada nível de temperatura e estrutura de vizinhança exercem influência sobre o comportamento do *Simulated Annealing* e devem ser definidos de acordo com as características do problema e do experimento realizado [Hillier and Lieberman 2006, van Laarhoven and Aarts 1987].

3. Metodologia

A metodologia adotada neste trabalho foi estruturada de forma a permitir a comparação experimental entre o Algoritmo Genético (AG) e o *Simulated Annealing* (SA) aplicados à mesma instância do Problema da Mochila 0/1. Para cada metaheurística foram definidas três configurações distintas. Os resultados das execuções foram organizados em uma escala padronizada de 10.000 posições de acompanhamento, nas quais é registrado o melhor valor da função objetiva encontrado até cada ponto da execução. Essa padronização permite analisar tanto a evolução das soluções quanto os resultados finais e a variabilidade observada entre as execuções.

3.1. Instância do Problema da Mochila

A instância utilizada nos experimentos, denominada `test_3.in`, é composta por 1.000 itens e possui capacidade máxima de 42.204 unidades. Foi utilizada uma instância do tipo **fortemente correlacionada** (*strongly correlated*), na qual o lucro de cada item é definido diretamente em função de seu peso.

A instância foi construída utilizando um gerador de testes para o Problema da Mochila 0/1 associado aos trabalhos de Pisinger [Pisinger 2005]. Na configuração utilizada neste experimento, o tipo 3 corresponde à categoria *strongly correlated*, sendo o lucro definido pela relação

$$p_i = w_i + 10,$$

em que p_i representa o lucro do item i e w_i representa seu peso.

A forte correlação entre peso e lucro reduz a capacidade de diferenciação entre os itens por relações simples de benefício e custo, tornando esse tipo de instância apropriado para avaliar o comportamento de métodos de busca metaheurística [Moradi et al. 2021].

O arquivo de entrada possui uma primeira linha contendo o número de itens, seguida por uma linha para cada item contendo seu identificador, lucro e peso. A última linha informa a capacidade máxima da mochila.

A Tabela 1 apresenta as principais características da instância utilizada.

Tabela 1. Características da instância `test_3.in`.

Característica	Valor
Número de itens (n)	1.000
Tipo da instância	Fortemente correlacionada
Relação entre lucro e peso	$p_i = w_i + 10$
Capacidade da mochila (W)	42.204
Arquivo de entrada	<code>test_3.in</code>

3.2. Estrutura do Experimento

Para permitir a comparação entre as configurações avaliadas, os resultados foram organizados em uma escala comum de 10.000 posições. Cada posição armazena o melhor valor da função objetiva encontrado até aquele ponto da execução. Dessa forma, para uma posição t , o valor registrado pode ser representado por

$$F_{\text{melhor}}(t) = \max\{f(X_0), f(X_1), \dots, f(X_t)\}.$$

Consequentemente, as séries produzidas apresentam comportamento não decrescente, uma vez que um melhor resultado previamente encontrado é preservado mesmo quando soluções posteriores apresentam qualidade inferior.

Embora a escala utilizada contenha 10.000 posições, nem todas correspondem necessariamente a novas avaliações efetivas da função objetiva. Dependendo do funcionamento e do critério de parada de cada algoritmo, uma execução pode terminar sua etapa de busca antes de preencher toda a série. Nesses casos, as posições restantes são completadas com o último melhor valor encontrado. Esse procedimento não introduz novas melhorias, sendo utilizado apenas para padronizar o comprimento das séries empregadas nos gráficos e nas comparações.

Considerando a natureza estocástica das metaheurísticas, foram realizadas 10 execuções para cada uma das seis configurações avaliadas. Os resultados de cada execução foram armazenados em colunas distintas dos arquivos CSV correspondentes. No *Simulated Annealing*, foram utilizadas sementes pseudoaleatórias sequenciais de 1 a 10, permitindo a reprodução das diferentes rodadas.

Para cada posição da escala, foi calculada a média dos melhores valores acumulados entre as 10 execuções de uma mesma configuração. Nos gráficos, o eixo horizontal representa a posição de acompanhamento da execução, enquanto o eixo vertical representa a média do melhor valor acumulado naquele ponto.

Além da evolução das curvas médias, foram calculadas estatísticas descritivas a partir do resultado final das 10 execuções de cada configuração. Para uma configuração com $n = 10$ execuções e resultados finais $x_1, x_2, \dots, x_n$, a média final é definida por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

A variabilidade entre as execuções foi avaliada por meio do desvio-padrão amostral, definido por

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}.$$

O uso do desvio-padrão permite observar a dispersão dos resultados finais obtidos pelas diferentes execuções de uma mesma configuração. Valores menores indicam menor variabilidade observada entre as execuções, enquanto valores maiores indicam maior dispersão dos resultados.

Dessa forma, a análise experimental considera principalmente três aspectos: a evolução média da qualidade das soluções ao longo da busca, a média dos melhores valores obtidos ao final das execuções e a variabilidade desses resultados finais.

3.3. Configurações do Algoritmo Genético

O Algoritmo Genético foi implementado em Python utilizando a biblioteca PyGAD [Gad 2021]. A implementação segue os princípios clássicos dos Algoritmos Genéticos, utilizando uma população de soluções candidatas submetidas aos processos de seleção, cruzamento e mutação [Goldberg 1989].

Cada indivíduo representa uma possível solução do Problema da Mochila 0/1 por meio de um vetor binário

$$X = (x_1, x_2, \dots, x_n),$$

em que

$$x_i \in \{0, 1\}.$$

Quando $x_i = 1$, o item i é selecionado para compor a mochila; quando $x_i = 0$, o item não pertence à solução.

A função objetivo utilizada é definida por

$$\text{Maximizar} \quad f(X) = \sum_{i=1}^n p_i x_i,$$

sujeita à restrição de capacidade

$$\sum_{i=1}^n w_i x_i \leq W.$$

Soluções que ultrapassam a capacidade máxima recebem aptidão igual a zero. Dessa forma,

$$\text{fitness}(X) = \begin{cases} \sum_{i=1}^n p_i x_i, & \text{se } \sum_{i=1}^n w_i x_i \leq W, \\ 0, & \text{caso contrário.} \end{cases}$$

Nas três configurações foi utilizada uma população de 100 indivíduos. Considerando a avaliação inicial da população e 99 gerações, foi estabelecida uma escala nominal correspondente a

$$100 + 99 \times 100 = 10\,000.$$

Cada chamada efetiva da função de aptidão é contabilizada durante a execução. Entretanto, devido ao funcionamento interno da biblioteca, a quantidade efetiva de chamadas pode ser inferior ao valor nominal. Quando isso ocorre, as posições restantes da série são preenchidas com o último melhor valor encontrado, conforme definido na Estrutura do Experimento.

As configurações avaliadas são apresentadas na Tabela 2.

Tabela 2. Configurações avaliadas do Algoritmo Genético.

Parâmetro	AG Original	AG Variação 1	AG Variação 2
População	100	100	100
Pais para cruzamento	30	30	15
Seleção	tournament	tournament	rank
K do torneio	Padrão	5	–
Cruzamento	two_points	two_points	uniform
Mutação	random	random	random
Genes mutados	5%	5%	4%
keep_parents	0	0	0
keep_elitism	0	0	1

O AG Original foi utilizado como configuração de referência, empregando 30 pais para cruzamento, seleção por torneio, cruzamento em dois pontos e mutação aleatória de 5%.

A Variação 1 preserva os principais parâmetros do AG Original e define explicitamente um torneio de tamanho cinco por meio de $K_{\text{tournament}}=5$. Dessa forma, a principal alteração em relação à configuração de referência está associada ao processo de seleção.

A Variação 2 apresenta alterações mais amplas, utilizando 15 pais, seleção por ranking, cruzamento uniforme e mutação de 4%. Nessa configuração também é utilizado $\text{keep_elitism}=1$, preservando um indivíduo por meio do mecanismo de elitismo.

Como diferentes parâmetros foram modificados simultaneamente na Variação 2, seu comportamento deve ser interpretado considerando o conjunto dessas alterações, não sendo possível atribuir os resultados observados isoladamente a um único parâmetro.

3.4. Configurações do *Simulated Annealing*

A implementação do *Simulated Annealing* utilizada neste trabalho foi baseada em uma implementação de código aberto aplicada ao Problema da Mochila 0/1 [Ferreira and Barroso 2024] e adaptada ao experimento realizado. Foram considerados os fundamentos do método apresentados por [Kirkpatrick et al. 1983] e o critério probabilístico baseado em [Metropolis et al. 1953].

Assim como no Algoritmo Genético, uma solução é representada por um vetor binário, no qual cada posição indica a inclusão ou exclusão de um item. A solução inicial é gerada aleatoriamente. Soluções que ultrapassam a capacidade máxima da mochila

recebem valor de aptidão igual a zero, mantendo a mesma estratégia de penalização utilizada no Algoritmo Genético.

A partir da solução corrente S , uma solução candidata S' é produzida por meio da inversão de M_{FLIP} posições distintas do vetor binário. Dessa forma, o parâmetro M_{FLIP} controla a extensão da perturbação realizada para gerar uma solução vizinha.

A função objetivo é de maximização. Assim, quando a solução candidata apresenta valor igual ou superior ao da solução corrente,

$$f(S') \geq f(S),$$

a solução candidata é aceita diretamente. Quando a candidata apresenta valor inferior, define-se

$$\Delta = f(S) - f(S'),$$

e sua aceitação ocorre probabilisticamente segundo

$$P(\text{aceitar } S') = \exp\left(-\frac{\Delta}{T}\right),$$

em que T representa a temperatura atual do algoritmo.

Dessa forma, temperaturas mais elevadas aumentam a possibilidade de aceitação de movimentos que reduzem temporariamente o valor da solução, enquanto temperaturas menores tornam esse comportamento progressivamente menos frequente.

Para cada nível de temperatura são realizadas até 100 iterações. Ao final desse conjunto, a temperatura é atualizada geometricamente segundo

$$T \leftarrow \alpha T.$$

A etapa de busca permanece ativa enquanto a quantidade máxima de avaliações não for atingida e a temperatura for maior ou igual a T_{MIN} . Caso a temperatura mínima seja alcançada antes do preenchimento das 10.000 posições da série, as posições restantes recebem o último melhor valor encontrado, seguindo o procedimento de padronização definido anteriormente.

Foram avaliadas três configurações. O SA Original foi utilizado como referência. A Variação 1 modifica o fator de resfriamento α , enquanto a Variação 2 modifica o número de posições invertidas durante a geração de cada solução vizinha, representado por M_{FLIP} .

A Tabela 3 apresenta os parâmetros utilizados.

Tabela 3. Configurações avaliadas do *Simulated Annealing*.

Parâmetro	SA Original	SA Variação 1	SA Variação 2
T_{MAX}	100.0	100.0	100.0
T_{MIN}	0.01	0.01	0.01
α	0.90	0.95	0.90
Iterações por nível	100	100	100
M_{FLIP}	2	2	5
Sementes utilizadas	1 a 10	1 a 10	1 a 10

O SA Original utiliza $T_{MAX} = 100.0$, $T_{MIN} = 0.01$, $\alpha = 0.90$ e $M_{FLIP} = 2$. Nessa configuração, cada solução vizinha é produzida pela inversão de duas posições distintas da solução corrente.

A Variação 1 mantém T_{MAX} , T_{MIN} e M_{FLIP} da configuração original e modifica o fator de resfriamento de $\alpha = 0.90$ para $\alpha = 0.95$. Como valores de α mais próximos de 1 produzem uma redução mais lenta da temperatura, essa configuração permite avaliar o comportamento da busca sob um cronograma de resfriamento mais gradual [Federici et al. 2019, Banchs 1997].

A Variação 2 mantém o cronograma de resfriamento da configuração original, mas aumenta M_{FLIP} de 2 para 5. Dessa forma, cada solução vizinha passa a apresentar cinco posições invertidas em relação à solução corrente, produzindo perturbações mais amplas no espaço de busca. Essa configuração permite analisar a influência da estrutura de vizinhança sobre o comportamento do algoritmo [Goldstein and Waterman 1988, Xinchao 2011].

As três configurações são analisadas utilizando a mesma escala padronizada de 10.000 posições definida na Estrutura do Experimento. Essa representação permite comparar a evolução do melhor valor acumulado entre as configurações, respeitando os critérios de parada específicos de cada execução.

Os códigos utilizados na implementação dos algoritmos, na execução dos experimentos e na geração e análise dos resultados estão disponíveis em um repositório público no GitHub [Silva et al. 2026].

4. Resultados Obtidos

4.1. Resultados do Algoritmo Genético

Nesta seção são apresentados os resultados obtidos a partir da execução de três configurações do Algoritmo Genético aplicadas ao Problema da Mochila 0/1. As configurações analisadas foram denominadas AG Original, AG Variação 1 e AG Variação 2. Cada configuração foi executada dez vezes, e os resultados foram organizados na escala padronizada de 10.000 posições de acompanhamento definida na metodologia.

Durante cada execução, foi registrado o melhor valor da função objetiva encontrado até cada ponto da execução. Dessa forma, os valores utilizados na análise não representam simplesmente o resultado da solução avaliada em cada instante, mas o melhor resultado acumulado desde o início da busca. Consequentemente, as curvas apresentam comportamento não decrescente e permitem observar tanto a rapidez com que cada configuração encontra soluções de maior qualidade quanto os períodos em que deixam de apresentar melhorias.

Os resultados foram armazenados em arquivos no formato CSV. O arquivo *saida.csv* contém os resultados do AG Original, *saida2.csv* os resultados do AG Variação 1 e *saida3.csv* os resultados do AG Variação 2. A primeira coluna de cada arquivo representa a posição de acompanhamento, enquanto as demais correspondem às dez execuções realizadas para cada configuração.

Para a construção dos gráficos, foi calculada, em cada posição, a média dos melhores valores acumulados nas dez execuções de cada configuração. A Figura 1 apresenta as três curvas em conjunto, possibilitando comparar diretamente a evolução média das configurações ao longo das 10.000 posições de acompanhamento.




Figura 1. Função objetiva média por posição de acompanhamento para as três configurações do Algoritmo Genético.

A Figura 1 evidencia comportamentos distintos entre as três configurações. O AG Variação 1 apresentou a maior média durante grande parte do processo de busca e terminou a execução com o maior valor médio. O AG Original apresentou comportamento

semelhante, com crescimento acentuado nas posições iniciais e melhorias adicionais ao longo da execução, porém permaneceu abaixo da primeira variação. Em contraste, o AG Variação 2 apresentou crescimento principalmente nas primeiras centenas de posições e, em seguida, permaneceu praticamente estabilizado em torno de 36.000 durante o restante da execução.

Os resultados finais das dez execuções de cada configuração foram utilizados para calcular a média e o desvio-padrão amostral. Esses valores são apresentados na Tabela 4.

Tabela 4. Resultados médios finais das configurações do Algoritmo Genético.

Configuração	Média final	Desvio-padrão
AG Original	42.603,2	262,51
AG Variação 1	44.198,8	383,51
AG Variação 2	35.999,2	656,27

O AG Variação 1 obteve a maior média final, superando o AG Original em 1.595,6 unidades da função objetiva, o que corresponde a aproximadamente 3,74% em relação ao resultado médio do AG Original. Em comparação ao AG Variação 2, a diferença foi de 8.199,6 unidades, aproximadamente 22,78% acima do valor obtido por essa configuração. Considerando a escala de acompanhamento utilizada no experimento, os resultados indicam que o AG Variação 1 apresentou o melhor desempenho médio entre as três configurações avaliadas.

Os desvios-padrão observados foram de 262,51 para o AG Original, 383,51 para o AG Variação 1 e 656,27 para o AG Variação 2. Dessa forma, o AG Original apresentou a menor variabilidade dos resultados finais entre as dez execuções, enquanto o AG Variação 2 apresentou a maior dispersão. O AG Variação 1, apesar de possuir desvio-padrão superior ao do AG Original, manteve a maior média final entre as configurações avaliadas.

Além do gráfico comparativo, foram gerados gráficos individuais para cada configuração. Esses gráficos facilitam a observação do comportamento de cada algoritmo separadamente, principalmente dos períodos de crescimento e estabilização das curvas.

4.1.1. AG Original

A Figura 2 apresenta a evolução média do AG Original.




Figura 2. Evolução média da função objetiva por posição de acompanhamento para o AG Original.

O AG Original utilizou população de 100 indivíduos, 30 pais para cruzamento, seleção por torneio, cruzamento em dois pontos e mutação aleatória de 5%. Além disso, foram definidos `keep_parents=0` e `keep_elitism=0`, não havendo preservação explícita de pais ou indivíduos por elitismo entre as gerações.

Conforme apresentado na Figura 2, o algoritmo iniciou a execução com média inferior a 33.000 e apresentou crescimento acentuado nas posições iniciais. A curva ultrapassou 40.000 ainda na parte inicial do processo de busca e continuou apresentando melhorias posteriormente, embora em frequência cada vez menor.

Após aproximadamente 4.000 posições, a curva passa a apresentar períodos maiores de estabilidade, intercalados por pequenas melhorias. Mesmo nas etapas mais avançadas, entretanto, ainda podem ser observados aumentos no melhor valor médio acumulado.

Ao final da escala de acompanhamento, o AG Original atingiu média de 42.603,2, correspondendo ao segundo melhor resultado entre as três configurações. O desvio-padrão de 262,51 foi o menor observado entre as configurações do AG, indicando menor variabilidade dos resultados finais entre as dez execuções dessa configuração.

4.1.2. AG Variação 1

A Figura 3 apresenta a evolução média obtida pelo AG Variação 1.




Figura 3. Evolução média da função objetiva por posição de acompanhamento para o AG Variação 1.

O AG Variação 1 manteve diversos parâmetros utilizados pelo AG Original: população de 100 indivíduos, 30 pais para cruzamento, seleção por torneio, cruzamento em dois pontos e mutação aleatória de 5%. Também foram mantidos `keep_parents=0` e `keep_elitism=0`. A principal alteração na seleção foi a definição explícita de `K_tournament=5`, fazendo com que cinco indivíduos participassem de cada disputa realizada pelo mecanismo de seleção por torneio.

A Figura 3 mostra que essa configuração apresentou crescimento acentuado desde as posições iniciais. A média ultrapassou 40.000 mais rapidamente que no AG Original e continuou aumentando durante uma parcela considerável da execução.

Mesmo após atingir valores próximos de 43.000, ainda podem ser observadas diversas pequenas melhorias. A partir de aproximadamente 6.000 posições, a curva apresenta maior estabilidade, mas ainda ocorrem alguns aumentos até as posições finais, levando a média para 44.198,8.

Entre as configurações avaliadas, o AG Variação 1 apresentou tanto o maior valor médio final quanto uma evolução mais rápida nas etapas iniciais. Seu desvio-padrão foi de 383,51, superior ao observado no AG Original, mas inferior ao apresentado pelo AG Variação 2.

Como os demais parâmetros principais são semelhantes aos utilizados no AG Original, os resultados mostram que a configuração com torneio de tamanho cinco apresentou melhor desempenho médio neste experimento. Entretanto, esses resultados devem ser interpretados considerando o conjunto do experimento. Embora a alteração no processo de seleção seja uma diferença importante entre as duas configurações, os resultados obtidos não permitem afirmar isoladamente que o valor de `K_tournament` seja, por si só, responsável por toda a diferença observada. O que pode ser afirmado é que, nas execuções realizadas para esta instância, a configuração adotada pelo AG Variação 1 alcançou os maiores valores médios entre as configurações do Algoritmo Genético avaliadas.

4.1.3. AG Variação 2

A Figura 4 apresenta a evolução média do AG Variação 2.




Figura 4. Evolução média da função objetiva por posição de acompanhamento para o AG Variação 2.

O AG Variação 2 utilizou uma configuração mais distinta das anteriores. Foram empregados 15 pais para cruzamento, seleção por ranking, cruzamento uniforme e mutação aleatória de 4%. A configuração também utilizou `keep_parents=0` e `keep_elitism=1`, preservando um indivíduo por meio do mecanismo de elitismo.

O comportamento observado na Figura 4 é bastante diferente daquele apresentado pelas demais configurações. O algoritmo iniciou com média próxima de 33.800 e apresentou crescimento rápido nas primeiras posições, atingindo aproximadamente 36.000 ainda no início da execução. Após esse ponto, praticamente não foram observadas novas melhorias durante o restante da escala de acompanhamento.

Essa longa estabilização indica que, nas execuções realizadas, a configuração perdeu rapidamente a capacidade de encontrar soluções superiores às já obtidas. Esse comportamento é compatível com uma possível convergência prematura, na qual a população passa a permanecer concentrada em uma determinada região do espaço de busca sem conseguir produzir soluções de maior qualidade.

Entretanto, não é possível atribuir esse comportamento exclusivamente a um único parâmetro. O AG Variação 2 modifica simultaneamente diferentes elementos do algoritmo, incluindo o método de seleção, o operador de cruzamento, a quantidade de pais, a taxa de mutação e a utilização de elitismo. Portanto, o desempenho observado deve ser interpretado como resultado da interação entre essas características.

A redução do número de pais de 30 para 15 diminui a quantidade de indivíduos diretamente envolvidos no processo de reprodução. Ao mesmo tempo, a seleção por ranking altera a forma como os indivíduos são escolhidos, enquanto o cruzamento uniforme modifica a maneira como os genes dos pais são combinados. A mutação de 4%, apesar de próxima dos 5% utilizados nas outras configurações, também representa uma alteração

no nível de perturbação aplicado às soluções. Além disso, a preservação de um indivíduo por elitismo modifica a dinâmica de substituição da população.

Dentro das condições utilizadas neste experimento, a combinação desses parâmetros não apresentou resultados favoráveis para a instância analisada. A média final foi de 35.999,2, aproximadamente 6.604,0 unidades inferior à do AG Original e 8.199,6 unidades inferior à do AG Variação 1. O desvio-padrão de 656,27 foi o maior entre as configurações do AG, indicando também maior variabilidade dos resultados finais entre as dez execuções.

4.1.4. Comparação Geral

A análise conjunta das Figuras 1, 2, 3 e 4 evidencia que a escolha dos parâmetros esteve associada a comportamentos distintos do Algoritmo Genético durante o processo de busca.

O AG Variação 1 apresentou o melhor desempenho médio entre as configurações analisadas, alcançando média final de 44.198,8 e desvio-padrão de 383,51. Além do maior resultado médio final, sua curva apresentou crescimento mais rápido nas etapas iniciais e permaneceu acima das demais durante grande parte da escala de acompanhamento.

O AG Original apresentou o segundo melhor resultado, com média final de 42.603,2 e desvio-padrão de 262,51. Embora sua média tenha sido inferior à obtida pela Variação 1, apresentou a menor variabilidade dos resultados finais entre as três configurações do AG.

O AG Variação 2 apresentou comportamento substancialmente diferente. Apesar de encontrar rapidamente soluções com média próxima de 36.000, a configuração praticamente deixou de apresentar melhorias após as primeiras centenas de posições. Como consequência, terminou a escala de acompanhamento com média de 35.999,2 e desvio-padrão de 656,27, apresentando simultaneamente a menor média final e a maior variabilidade entre as configurações analisadas.

Os resultados demonstram também a importância de analisar não apenas os valores médios finais, mas também a evolução das soluções e sua variabilidade entre execuções. Enquanto o AG Original e o AG Variação 1 continuaram encontrando soluções melhores durante uma parcela considerável da escala de acompanhamento, o AG Variação 2 permaneceu estabilizado durante grande parte da série após seu crescimento inicial.

Para a instância considerada e nas condições deste experimento, o AG Variação 1 apresentou o melhor desempenho médio entre as alternativas avaliadas. Contudo, como cada variação utiliza parametrizações específicas e os resultados são referentes a uma única instância experimental, não se pode generalizar que essa configuração será necessariamente superior em outros problemas ou instâncias. Os resultados permitem concluir apenas que, dentro do cenário avaliado, as escolhas realizadas no AG Variação 1 proporcionaram o melhor desempenho médio entre as três configurações testadas.

4.2. Resultados do *Simulated Annealing*

Nesta seção são apresentados os resultados obtidos pelas três configurações do *Simulated Annealing* aplicadas ao Problema da Mochila 0/1. As configurações analisadas foram

denominadas SA Original, SA Variação 1 e SA Variação 2. O SA Original foi utilizado como configuração de referência, enquanto a Variação 1 modifica o fator de resfriamento α e a Variação 2 modifica o parâmetro de vizinhança M_{FLIP} .

Cada configuração foi executada dez vezes, utilizando sementes pseudoaleatórias sequenciais de 1 a 10. Para cada posição da escala de acompanhamento, foi registrado o melhor valor da função objetiva encontrado até aquele momento e, posteriormente, calculada a média entre as dez execuções. Os resultados foram armazenados nos arquivos `saida1_sa.csv`, `saida2_sa.csv` e `saida3_sa.csv`, correspondentes, respectivamente, ao SA Original, SA Variação 1 e SA Variação 2.

A Figura 5 apresenta a evolução média das três configurações ao longo da escala padronizada de 10.000 posições utilizada no experimento.




Figura 5. Comparação da evolução média das configurações do *Simulated Annealing*.

A Figura 5 mostra que as três configurações apresentam crescimento acentuado da média do melhor valor acumulado nas etapas iniciais da execução. À medida que a busca progride, as melhorias tornam-se menos frequentes, produzindo períodos maiores de estabilidade nas curvas.

Apesar de apresentarem comportamento semelhante nas posições iniciais, diferenças entre as configurações podem ser observadas ao longo da execução. O SA Variação 2 mantém a maior média durante grande parte da escala de acompanhamento e termina com o maior valor médio final. O SA Variação 1 apresenta o segundo maior resultado médio, seguido pelo SA Original.

Os resultados finais das dez execuções de cada configuração foram utilizados para calcular a média e o desvio-padrão amostral. Esses valores são apresentados na Tabela 5.

Tabela 5. Resultados médios finais das configurações do *Simulated Annealing*.

Configuração	Média final	Desvio-padrão
SA Original	49.364,3	53,75
SA Variação 1	49.452,0	49,48
SA Variação 2	49.833,3	45,38

4.2.1. SA Original

A Figura 6 apresenta individualmente a evolução média da configuração SA Original.




Figura 6. Evolução média da função objetiva para o SA Original.

O SA Original utiliza $T_{MAX} = 100.0$, $T_{MIN} = 0.01$, fator de resfriamento $\alpha = 0.90$ e $M_{FLIP} = 2$. Dessa forma, cada solução vizinha é produzida pela inversão de duas posições distintas da representação binária.

A curva mostra que essa configuração apresenta suas principais melhorias durante as posições iniciais da escala de acompanhamento. Posteriormente, os ganhos tornam-se menos frequentes e a média do melhor valor acumulado permanece estável durante períodos maiores.

Com $\alpha = 0.90$, a temperatura é reduzida após cada conjunto de iterações. Quando a temperatura se torna inferior a T_{MIN} , a etapa de busca é encerrada. Caso isso ocorra antes do preenchimento das 10.000 posições utilizadas para registro dos resultados, as posições restantes mantêm o último melhor valor encontrado. Dessa forma, a região final constante da curva não representa necessariamente a realização de novas perturbações, podendo incluir a manutenção do melhor resultado obtido durante a busca.

Ao final das dez execuções, o SA Original apresentou média final de 49.364,3 unidades da função objetiva e desvio-padrão de 53,75.

4.2.2. SA Variação 1

A Figura 7 apresenta individualmente a evolução média da configuração SA Variação 1.




Figura 7. Evolução média da função objetiva para o SA Variação 1.

A Variação 1 mantém $T_{MAX} = 100.0$, $T_{MIN} = 0.01$ e $M_{FLIP} = 2$, alterando o fator de resfriamento de $\alpha = 0.90$ para $\alpha = 0.95$. Como a temperatura é atualizada segundo um fator multiplicativo, o valor mais próximo de 1 provoca um resfriamento mais lento.

Consequentemente, essa configuração permanece por mais tempo em níveis de temperatura elevados e intermediários. Nessas condições, movimentos que reduzem temporariamente o valor da solução corrente permanecem com possibilidade de aceitação durante uma parcela maior da execução.

A Figura 7 mostra crescimento acentuado nas posições iniciais, seguido por melhorias progressivamente menos frequentes. Ao final das dez execuções, a configuração apresentou média de 49.452,0 unidades da função objetiva e desvio-padrão de 49,48.

Em relação ao SA Original, a Variação 1 apresentou média final 87,7 unidades superior, correspondendo a aproximadamente 0,18%. Além disso, seu desvio-padrão foi ligeiramente menor que o observado na configuração original, indicando menor variabilidade dos resultados finais entre as dez execuções realizadas.

Como a principal alteração entre essas configurações é o fator de resfriamento, os resultados indicam que, para a instância considerada e nas condições deste experimento, a configuração com $\alpha = 0.95$ esteve associada a uma média final ligeiramente superior à obtida com $\alpha = 0.90$.

4.2.3. SA Variação 2

A Figura 8 apresenta individualmente a evolução média da configuração SA Variação 2.




Figura 8. Evolução média da função objetiva para o SA Variação 2.

A Variação 2 mantém os parâmetros de temperatura da configuração original, incluindo $\alpha = 0.90$, mas aumenta M_{FLIP} de 2 para 5. Na implementação utilizada, esse parâmetro determina diretamente a quantidade de posições distintas invertidas durante a geração de cada solução vizinha. Dessa forma, enquanto o SA Original modifica duas posições por perturbação, a Variação 2 modifica cinco.

A utilização de $M_{FLIP} = 5$ produz movimentos mais amplos no espaço de soluções, uma vez que cada solução candidata apresenta uma quantidade maior de diferenças em relação à solução corrente. No experimento realizado, essa configuração apresentou crescimento acentuado nas posições iniciais e continuou registrando melhorias ao longo de uma parcela maior da escala de acompanhamento.

Ao final das dez execuções, o SA Variação 2 apresentou média final de 49.833,3 unidades da função objetiva e desvio-padrão de 45,38, correspondendo ao maior valor médio final e ao menor desvio-padrão entre as três configurações avaliadas.

Em relação ao SA Original, a Variação 2 apresentou média 469,0 unidades superior, correspondendo a aproximadamente 0,95%. Quando comparada à Variação 1, a diferença foi de 381,3 unidades, aproximadamente 0,77%.

Os resultados indicam que, nas condições deste experimento, a configuração com $M_{FLIP} = 5$ esteve associada ao melhor desempenho médio entre as alternativas avaliadas e à menor variabilidade observada nos resultados finais das dez execuções. Entretanto, não é possível concluir que o aumento desse parâmetro produza necessariamente resultados superiores ou menor variabilidade em outras instâncias ou configurações do Problema da Mochila.

4.2.4. Comparação Geral

A análise conjunta das três configurações mostra que todas apresentam crescimento acentuado nas etapas iniciais da busca, seguido por uma redução progressiva na frequência de

novos melhores resultados.

O SA Original apresentou média final de 49.364,3 unidades da função objetiva e desvio-padrão de 53,75. A Variação 1 alcançou média de 49.452,0 e desvio-padrão de 49,48, correspondendo a uma diferença de 87,7 unidades, ou aproximadamente 0,18%, em relação à média da configuração de referência. O SA Variação 2 apresentou a maior média final, com 49.833,3 unidades e desvio-padrão de 45,38, superando o SA Original em 469,0 unidades, aproximadamente 0,95%, e a Variação 1 em 381,3 unidades, aproximadamente 0,77%.

Em relação à variabilidade dos resultados finais, os desvios-padrão diminuíram de 53,75 no SA Original para 49,48 na Variação 1 e 45,38 na Variação 2. Dessa forma, entre as configurações avaliadas, a Variação 2 apresentou simultaneamente a maior média final e a menor variabilidade observada entre as dez execuções.

A Variação 1 altera o comportamento do resfriamento por meio do aumento de α , enquanto a Variação 2 altera a extensão das perturbações realizadas na solução por meio de M_{FLIP} . Para a instância analisada, a configuração empregada na Variação 2 esteve associada ao maior resultado médio final observado.

Esses resultados mostram que tanto o cronograma de resfriamento quanto a definição da vizinhança estiveram associados a comportamentos distintos do *Simulated Annealing*. Entretanto, como o experimento considera configurações específicas e uma única instância do Problema da Mochila 0/1, os resultados não devem ser generalizados para outras instâncias ou parametrizações.

4.3. Comparação entre as Metaheurísticas

Após a análise individual das configurações do Algoritmo Genético (AG) e do *Simulated Annealing* (SA), foi realizada uma comparação entre as configurações que apresentaram os melhores resultados médios em cada metaheurística. Entre as configurações do AG, o melhor desempenho médio foi obtido pelo AG Variação 1, com média final de 44.198,8 unidades da função objetiva e desvio-padrão de 383,51. Entre as configurações do SA, o melhor resultado médio foi obtido pelo SA Variação 2, com média final de 49.833,3 unidades e desvio-padrão de 45,38.

A Figura 9 apresenta a evolução média dessas duas configurações na escala padronizada de 10.000 posições de acompanhamento utilizada no experimento. Essa representação permite observar o comportamento do melhor valor acumulado ao longo das execuções, considerando os critérios de parada específicos de cada metaheurística.




Figura 9. Comparação entre as melhores configurações do Algoritmo Genético e do *Simulated Annealing*.

A Figura 9 evidencia comportamentos distintos entre as duas metaheurísticas. O AG Variação 1 apresenta uma evolução gradual ao longo de grande parte da execução. Nas posições iniciais, observa-se crescimento acentuado do melhor valor acumulado médio, seguido por melhorias progressivamente menores e mais espaçadas. A configuração continua apresentando ganhos durante etapas posteriores da busca, alcançando média final de 44.198,8 unidades da função objetiva.

O SA Variação 2, por sua vez, apresenta crescimento mais acentuado nas etapas iniciais. A média do melhor valor acumulado aumenta rapidamente e alcança valores próximos de 49.000 ainda em uma parcela inicial da escala de acompanhamento. Posteriormente, as melhorias passam a ocorrer com menor frequência, embora novos ganhos continuem sendo observados ao longo da execução, até que a média final atinja 49.833,3 unidades.

A diferença entre as médias finais das melhores configurações foi de 5.634,5 unidades da função objetiva em favor do SA Variação 2. Em relação à média obtida pelo AG Variação 1, essa diferença corresponde a aproximadamente 12,75%. Dessa forma, para a instância analisada e nas condições deste experimento, o SA Variação 2 alcançou soluções de maior valor médio do que o AG Variação 1.

Além da diferença entre as médias, também foi observada uma diferença na variabilidade dos resultados finais. O AG Variação 1 apresentou desvio-padrão de 383,51, enquanto o SA Variação 2 apresentou desvio-padrão de 45,38. Assim, entre as dez execuções realizadas, o SA Variação 2 apresentou menor dispersão dos resultados finais em torno de sua média.

A Tabela 6 resume os resultados das melhores configurações de cada metaheurística.

Tabela 6. Comparação entre as melhores configurações do AG e do SA.

Configuração	Média final	Desvio-padrão
AG Variação 1	44.198,8	383,51
SA Variação 2	49.833,3	45,38

Além do maior valor médio final e da menor variabilidade observada entre as execuções, a curva do SA Variação 2 indica que valores elevados da função objetiva foram alcançados em uma etapa anterior da escala de acompanhamento. Entretanto, essa comparação deve considerar que as 10.000 posições utilizadas nos gráficos não representam necessariamente 10.000 novas avaliações efetivas em todas as configurações, uma vez que os algoritmos possuem critérios de parada distintos e podem completar as posições restantes com o último melhor valor encontrado.

As diferenças de comportamento também podem ser relacionadas às estratégias de busca utilizadas por cada metaheurística. No Algoritmo Genético, a evolução ocorre por meio de uma população de soluções submetida aos mecanismos de seleção, cruzamento e mutação. No AG Variação 1, as melhorias tornam-se progressivamente menos frequentes ao longo da execução, embora ainda sejam observados ganhos em etapas posteriores.

O *Simulated Annealing*, por sua vez, trabalha com uma única solução corrente e permite a aceitação probabilística de movimentos que reduzam temporariamente o valor da função objetivo. Quando uma solução candidata apresenta valor inferior ao da solução corrente, sua aceitação depende da temperatura e da magnitude da redução, conforme o critério baseado em Metropolis [Metropolis et al. 1953, Kirkpatrick et al. 1983]. Em temperaturas mais elevadas, movimentos de piora apresentam maior probabilidade de aceitação; à medida que a temperatura é reduzida, essa probabilidade diminui progressivamente.

No SA Variação 2, a estrutura de vizinhança utiliza $M_{FLIP} = 5$, fazendo com que cada solução candidata seja produzida pela inversão de cinco posições distintas da representação binária. Em comparação ao SA Original, que utiliza $M_{FLIP} = 2$, essa configuração produz perturbações mais amplas no espaço de soluções. Nas dez execuções realizadas, essa parametrização apresentou a maior média final e o menor desvio-padrão entre as configurações do SA avaliadas. Entretanto, não é possível afirmar que o aumento de M_{FLIP} produzirá necessariamente o mesmo comportamento em outras instâncias ou parametrizações.

A característica fortemente correlacionada (*strongly correlated*) da instância também deve ser considerada na interpretação dos resultados. Nesse tipo de instância, peso e lucro apresentam uma relação direta, o que influencia a estrutura do espaço de soluções e o comportamento das estratégias de busca [Moradi et al. 2021].

Os resultados obtidos não devem ser interpretados como evidência de superioridade geral do *Simulated Annealing* sobre o Algoritmo Genético. O experimento considera uma única instância do Problema da Mochila 0/1 e configurações específicas das duas metaheurísticas. Além disso, as diferenças observadas são de natureza descritiva, não tendo sido realizados testes estatísticos inferenciais para avaliar a significância das diferenças entre os métodos. Alterações na instância, nos operadores empregados ou nos parâmetros

utilizados podem modificar o desempenho relativo das metaheurísticas.

Dentro das condições avaliadas neste trabalho, o SA Variação 2 apresentou a maior média final e a menor variabilidade entre as melhores configurações de cada metaheurística, alcançando média de 49.833,3 e desvio-padrão de 45,38, enquanto o AG Variação 1 apresentou média de 44.198,8 e desvio-padrão de 383,51. Dessa forma, para a instância e as parametrizações consideradas, o *Simulated Annealing*, representado por sua Variação 2, apresentou o melhor desempenho médio observado entre as duas metaheurísticas.

5. Conclusão

Este trabalho apresentou uma análise comparativa entre as metaheurísticas Algoritmo Genético (AG) e *Simulated Annealing* (SA) aplicadas ao Problema da Mochila 0/1. Foram avaliadas três configurações de cada metaheurística utilizando a mesma instância fortemente correlacionada. Para cada configuração foram realizadas dez execuções, e os resultados foram organizados em uma escala padronizada de 10.000 posições de acompanhamento do melhor valor acumulado. A análise considerou a evolução média das soluções, os resultados médios finais e a variabilidade observada entre as execuções.

Entre as configurações do Algoritmo Genético, o AG Variação 1 apresentou o melhor desempenho médio, alcançando média final de 44.198,8 unidades da função objetiva e desvio-padrão de 383,51. O AG Original obteve o segundo melhor resultado, com média de 42.603,2 e desvio-padrão de 262,51, apresentando a menor variabilidade entre as configurações do AG. O AG Variação 2 apresentou estabilização precoce da curva em valores próximos de 36.000, terminando com média de 35.999,2 e desvio-padrão de 656,27, o maior entre as três configurações. Os resultados mostram que diferentes escolhas de parâmetros de seleção, cruzamento, mutação e elitismo estiveram associadas a comportamentos distintos tanto em relação à qualidade média das soluções quanto à variabilidade dos resultados.

Nas configurações do *Simulated Annealing*, também foram observadas diferenças associadas às alterações realizadas no fator de resfriamento e na estrutura de vizinhança. O SA Original apresentou média final de 49.364,3 unidades da função objetiva e desvio-padrão de 53,75, enquanto a Variação 1 alcançou média de 49.452,0 e desvio-padrão de 49,48. O SA Variação 2, configurado com $M_{FLIP} = 5$, apresentou o melhor desempenho médio entre as configurações do SA, alcançando média final de 49.833,3 unidades e desvio-padrão de 45,38. Dessa forma, essa configuração apresentou simultaneamente a maior média final e a menor variabilidade observada entre as dez execuções das configurações do SA.

A análise das curvas indica ainda diferenças no comportamento das duas metaheurísticas. O AG Variação 1 apresentou uma evolução mais gradual, mantendo pequenas melhorias durante uma parcela maior da execução. O SA Variação 2, por sua vez, alcançou valores elevados da função objetiva em uma etapa anterior da escala de acompanhamento e continuou apresentando melhorias ao longo da execução, ainda que com frequência progressivamente menor. Deve-se considerar, entretanto, que as 10.000 posições utilizadas para padronizar as séries não correspondem necessariamente a novas avaliações efetivas em todos os pontos, uma vez que os algoritmos possuem critérios de parada próprios e podem manter o último melhor valor nas posições restantes.

Na comparação entre as melhores configurações de cada metaheurística, o SA Variação 2 apresentou média final de 49.833,3 unidades e desvio-padrão de 45,38, enquanto o AG Variação 1 alcançou média de 44.198,8 e desvio-padrão de 383,51. A diferença entre as médias foi de 5.634,5 unidades da função objetiva, correspondendo a aproximadamente 12,75% em relação ao resultado do AG Variação 1. Além da maior média final, o SA Variação 2 apresentou menor dispersão dos resultados entre as dez execuções realizadas. Dessa forma, para a instância e as parametrizações consideradas neste experimento, o *Simulated Annealing*, representado por sua Variação 2, apresentou o melhor desempenho médio observado entre as duas metaheurísticas.

Entretanto, os resultados não devem ser interpretados como evidência de superioridade geral do *Simulated Annealing* sobre o Algoritmo Genético. O experimento foi realizado sobre uma única instância do Problema da Mochila 0/1 e com conjuntos específicos de parâmetros. Além disso, as diferenças observadas entre as médias e os desvios-padrão possuem caráter descritivo, uma vez que não foram realizados testes estatísticos inferenciais para verificar a significância das diferenças entre os métodos. Alterações nos operadores, no cronograma de resfriamento, na estrutura de vizinhança ou nas características da instância podem modificar o desempenho relativo das metaheurísticas.

Os experimentos reforçam, portanto, a importância da escolha e do ajuste dos parâmetros em métodos de busca metaheurística, bem como da análise do comportamento das soluções ao longo da execução, dos valores médios finais e da variabilidade entre execuções. Como trabalhos futuros, podem ser avaliadas novas configurações dos algoritmos, diferentes estratégias de vizinhança e operadores genéticos, além de um conjunto maior e mais diversificado de instâncias do Problema da Mochila 0/1. Também podem ser incorporadas análises estatísticas adicionais, como intervalos de confiança e testes de significância, permitindo uma comparação mais abrangente e aumentando a capacidade de generalização dos resultados.

Referências

- Banchs, R. E. (1997). Simulated annealing. Notas de curso, Universitat Politècnica de Catalunya.
- Federici, L., Zavoli, A., and Colasurdo, G. (2019). A time-dependent TSP formulation for the design of an active debris removal mission using simulated annealing.
- Ferreira, J. V. d. S. and Barroso, P. H. d. S. (2024). Knapsack-Simulated-Annealing: Implementação do problema da mochila utilizando simulated annealing. Disponível em: <https://github.com/JVictor011/Knapsack-Simulated-Annealing/>. Acesso em: 04 jul. 2026.
- Gad, A. F. (2021). PyGAD: An intuitive genetic algorithm python library. *arXiv preprint arXiv:2106.06158*.
- Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, Reading, Massachusetts.
- Goldstein, L. and Waterman, M. (1988). Neighborhood size in the simulated annealing algorithm. *American Journal of Mathematical and Management Sciences*, 8(3-4):409–423.
- Hillier, F. S. and Lieberman, G. J. (2006). *Introdução à Pesquisa Operacional*. McGraw-Hill Interamericana do Brasil Ltda., São Paulo, 8 edition.
- Kirkpatrick, S., Gelatt Jr., C. D., and Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598):671–680.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., and Teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6):1087–1092.
- Moradi, N., Kayvanfar, V., and Rafiee, M. (2021). An efficient population-based simulated annealing algorithm for 0–1 knapsack problem. *Engineering with Computers*, 38(3):2771–2790.
- Pisinger, D. (2005). Where are the hard knapsack problems? *Computers & Operations Research*, 32(9):2271–2284.
- Silva, J. V. F. d., Manuares, M. A. d. S., and Dias, S. C. (2026). Relatório de ia: Algoritmo genético e simulated annealing aplicados ao problema da mochila 0/1. Disponível em: <https://github.com/Vitor5005/Relatorio-De-IA>. Acesso em: 14 ago. 2026.
- van Laarhoven, P. J. M. and Aarts, E. H. L. (1987). *Simulated Annealing: Theory and Applications*. D. Reidel Publishing Company, Dordrecht.
- Xinchao, Z. (2011). Simulated annealing algorithm with adaptive neighborhood. *Applied Soft Computing*, 11(2):1827–1836.